

Implementação de um sistema de previsão de safra baseado em TinyML

Luis Enrique Cardozo Ramirez Brithany Michelle Oliva Chuquimia
Registro 949 Registro 971
INATEL INATEL
Santa Rita do Sapucaí- MG Brasil Santa Rita do Sapucaí- MG Brasil

Este projeto apresenta um sistema de previsão de produção agrícola usando TinyML, uma técnica de aprendizado de máquina otimizada para microcontroladores de baixo consumo. Usando variáveis ambientais e do solo como entrada, modelos leves são implementados em dispositivos como o ESP32, permitindo inferências locais sem conexão com a nuvem. A proposta visa fornecer uma solução econômica, autônoma e eficiente em termos de energia para ambientes agrícolas com infraestrutura limitada. Desafios como a otimização de modelos, a qualidade dos dados e a generalização para diferentes condições agronômicas são abordados, contribuindo para o desenvolvimento de tecnologias sustentáveis para a agricultura de precisão

Palavras-chave: TinyML, agricultura de precisão, previsão de produtividade de culturas

I. INTRODUÇÃO (TÍTULO I)

O aprendizado de máquina provou ser uma ferramenta eficaz na agricultura de precisão, melhorando a previsão de rendimento, a análise do solo e a detecção de doenças. Modelos como Random Forest, Support Vector Machines e redes neurais alcançaram altas taxas de precisão (até 99,93%, de acordo com Surana e Khandelwal, 2024), mas sua implementação geralmente depende de altos recursos computacionais, o que limita sua aplicabilidade em ambientes rurais com infraestrutura restrita.

O TinyML, um ramo do aprendizado de máquina projetado para dispositivos com recursos limitados, surge como uma alternativa viável para esses cenários. Ao executar modelos otimizados em microcontroladores de baixo consumo de energia, como o ESP32, ele permite que as inferências sejam feitas localmente. Estruturas como o TensorFlow Lite for Microcontrollers demonstraram viabilidade usando técnicas de quantização e poda, alcançando um uso eficiente da memória (<1 MB) e tempos de inferência inferiores a um segundo.

Este projeto propõe um sistema de previsão de produtividade de culturas baseado no TinyML, que opera de forma autônoma em microcontroladores. Usando variáveis ambientais (temperatura, umidade, precipitação) e do solo (pH, umidade), o sistema visa a oferecer uma solução de baixo custo. A iniciativa se baseia em estudos anteriores, mas busca superar os principais desafios, como a generalização para diferentes culturas, a qualidade dos dados e a robustez do sistema em condições reais. Assim, ela contribui para o desenvolvimento de ferramentas

acessíveis para a agricultura inteligente, com impacto direto na otimização de recursos e no planejamento da produção em áreas com limitações tecnológicas.

II. DESCRIÇÃO TÉCNICA

Este projeto propõe o desenvolvimento de um sistema de previsão de produtividade de culturas usando TinyML, um ramo de aprendizado de máquina otimizado para dispositivos com recursos computacionais limitados. Ele propõe a implementação de modelos de redes neurais leves em microcontroladores de baixo consumo, como o ESP32 ou o Arduino Nano, para inferir a produtividade das culturas a partir de variáveis ambientais e do solo, como temperatura, umidade, precipitação e pH. A solução é voltada para operar de forma autônoma e eficiente em ambientes agrícolas com infraestrutura limitada. O sistema tem como objetivo fornecer uma ferramenta de agricultura inteligente de baixo custo e com capacidade local, abordando desafios como a variabilidade climática, a heterogeneidade do terreno e a escassez de sistemas avançados de monitoramento. Entre os principais desafios técnicos estão a compactação e a otimização de modelos para serem executados em uma memória restrita, a coleta de dados agrícolas representativos e o projeto de algoritmos robustos que se generalizem bem para diferentes condições ambientais e tipos de cultura. Essa iniciativa contribui para o desenvolvimento de tecnologias agrícolas inteligentes destinadas a aumentar a eficiência do planejamento da produção e do gerenciamento de recursos em contextos rurais ou com restrições de infraestrutura.

III. RELEVÂNCIA E MOTIVAÇÃO DO TÓPICO

A agricultura enfrenta desafios críticos devido às mudanças climáticas, ao aumento da demanda por alimentos e à necessidade de práticas sustentáveis. A capacidade de prever o rendimento das colheitas é um fator essencial para otimizar recursos como água, fertilizantes e tempo. O uso do TinyML, uma abordagem de aprendizado de máquina otimizada para dispositivos de baixo consumo de energia, oferece uma solução inovadora ao permitir previsões locais sem depender de conectividade em nuvem, reduzindo assim os custos e o consumo de energia. Esse projeto é relevante porque atende à necessidade de ferramentas de agricultura de precisão que sejam acessíveis, dimensionáveis e sustentáveis, promovendo a segurança e a eficiência alimentar em contextos rurais. A motivação está no fato de capacitar pequenos e médios

produtores agrícolas com tecnologia acessível que melhora a tomada de decisões e reduz os riscos de produção.

IV. DESCRIÇÃO DO PROBLEMA

A agricultura moderna enfrenta incertezas na previsão da produção agrícola devido à variabilidade climática, à heterogeneidade do solo e à falta de ferramentas de monitoramento acessíveis em regiões com infraestrutura limitada. Os sistemas de previsão tradicionais dependem da computação em nuvem, o que implica altos custos operacionais, dependência de conectividade e alto consumo de energia, fatores que os tornam inviáveis em ambientes remotos. Este projeto busca solucionar a falta de sistemas de previsão de safra que sejam autônomos, eficientes em termos de energia e capazes de operar localmente em hardware de baixa potência. A ausência de tais ferramentas limita a capacidade dos agricultores de otimizar recursos, planejar colheitas e mitigar riscos, afetando a produtividade e a sustentabilidade agrícola.

V. HIPÓTESE

Hipótese: Um sistema baseado em TinyML, implementado em microcontroladores como o ESP32, pode prever o rendimento das colheitas (em termos de quantidade) usando variáveis como temperatura, umidade, precipitação, pH e umidade do solo, mantendo o consumo de energia baixo e operando de forma autônoma em ambientes agrícolas com recursos limitados.

VI. METODOLOGIA

A metodologia proposta consiste em cinco fases para desenvolver, implementar e avaliar o sistema de previsão de safra baseado em TinyML:

1. Coleta de dados:

- **Fontes:** Os dados agrícolas serão obtidos de plataformas de acesso aberto, como o Kaggle, complementados com dados de sensores de IoT que medem a temperatura, a umidade relativa, a precipitação, o pH e a umidade do solo.
- **Pré-processamento:** limpeza de dados (eliminação de outliers), normalização e redução da dimensionalidade usando técnicas como a análise de componentes principais (PCA) para otimizar o uso da memória em microcontroladores.
- **Diversidade:** assegure-se de que os dados abranjam diferentes culturas (por exemplo, milho, trigo) e condições climáticas (por exemplo, tropical, árido) para melhorar a generalização do modelo.

2. Desenvolvimento de modelos:

- **Treinamento inicial:** os modelos de ML (Lightweight Neural Networks, Random Forest) serão treinados em um ambiente mais avançado do ponto de vista computacional usando o TensorFlow e o Scikit-learn.

- **Otimização para TinyML:** os modelos serão otimizados com o TensorFlow Lite Micro, aplicando quantização (INT8) e poda de parâmetros para reduzir o tamanho do modelo e o tempo de inferência.
- **Seleção de modelos:** os modelos serão comparados em termos de precisão, latência e consumo de energia, selecionando o modelo mais adequado para a implantação do hardware.

3. Implementação de hardware:

- **Plataforma:** Um microcontrolador ESP32 será usado por sua capacidade de processamento, baixo consumo de energia e compatibilidade com o TensorFlow Lite Micro.
- **Pipeline:** um sistema de aquisição de dados de sensores de IoT, pré-processamento local e inferência serão integrados ao dispositivo.
- **Teste inicial:** a funcionalidade do sistema será verificada em um ambiente controlado, avaliando a estabilidade e a latência das inferências.

4. Avaliação:

- **Métricas:** serão avaliadas a precisão (R^2 , RMSE), a latência da inferência, o consumo de energia e a robustez dos dados reais.
- **Validação cruzada:** a validação cruzada com dados de diferentes regiões e culturas será aplicada para garantir a generalização.
- **Benchmarking:** o desempenho do sistema será comparado com modelos tradicionais em execução na nuvem para validar sua viabilidade.

5. Teste piloto:

- **Ambiente:** o sistema será implementado em um ambiente agrícola real (por exemplo, um campo de milho ou trigo) durante um ciclo de colheita.
- **Feedback:** o feedback será coletado dos agricultores sobre a usabilidade e a eficácia do sistema.
- **Ajustes:** os aprimoramentos serão feitos com base nos resultados do teste piloto, otimizando o modelo e o hardware, se necessário.

VII. CONTRIBUIÇÕES ESPERADAS

O projeto fornecerá uma solução inovadora para a agricultura de precisão, demonstrando a viabilidade do TinyML em microcontroladores para previsões agrícolas em tempo real. Espera-se gerar conhecimento sobre a otimização de modelos de aprendizado de máquina em ambientes de baixo consumo de energia, bem como uma arquitetura de sistema dimensionável e de baixo custo para produtores agrícolas de pequeno e médio porte.

REFERÊNCIAS

- [1] Manzoor, M. F. (2024). A Review of Machine Learning Techniques for Precision Agriculture and Crop Yield Prediction (Uma revisão das técnicas de aprendizado de máquina para agricultura de precisão e previsão de rendimento de culturas). Premier Journal of Plant Biology, 1, 100005. DOI: <https://doi.org/10.70389/PJPB.100005>
- [2] Surana, R., & Khandelwal, R. (2024). Crop Yield Prediction Using Machine Learning: A Pragmatic Approach (Previsão de rendimento de culturas usando aprendizado de máquina: uma abordagem pragmática). Research Square. DOI: <https://doi.org/10.21203/rs.3.rs-4575893/v1>